

Lehrveranstaltung

Informationstheorie

— *Sommersemester 2023* —

Martin Mittelbach (Vorlesung, Tutorium), Anne Wolf (Übung, Tutorium)
{martin.mittelbach, anne.wolf}@tu-dresden.de

Professur für Informationstheorie und maschinelles Lernen, TU Dresden

Vorlesung 5
26. April 2023

Wiederholung

- **Mathematisches Datenmodell:**

(stationäre) Folge diskreter Zufallsgrößen = (stationäre) Quelle

$$X_1, X_2, X_3, X_4, \dots$$


speziell: (stationäre) gedächtnislose Quelle / (stationäre) Markow-Quelle

- **Codierung** der Werte einzelner Zufallsgrößen X_k mit Alphabet $\mathcal{X} = \{1, 2, \dots, M\}$ und W-Funktion p mit

D -wertigem (Quellen-) Code \mathcal{C} variabler Länge.

Quelle (Folge von Zufallsgrößen):	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	...
mögliche Werte der Zufallsgrößen:	1	2	1	1	3	2	1	4	...
	↓	↓	↓	↓	↓	↓	↓	↓	...
Codierung:	0	10	0	0	110	10	0	111	...

- **Codeklassen:**



Wiederholung

- **Bewertungskriterium:** Mittlere Codewortlänge



$$\bar{\ell} = \bar{\ell}(\mathcal{C}, p) = \sum_{i=1}^M p(i) \ell(i)$$

- **Optimale Codes:** Präfixfreie/eindeutig decodierbare Codes mit **minimaler** mittlerer Codewortlänge

$$\bar{\ell}_{\text{ud}}^* = \bar{\ell}_{\text{ud}}^*(p) = \min \{ \bar{\ell}(\mathcal{C}, p) : \mathcal{C} \text{ eindeutig decodierbar} \}$$

$$\bar{\ell}_{\text{pre}}^* = \bar{\ell}_{\text{pre}}^*(p) = \min \{ \bar{\ell}(\mathcal{C}, p) : \mathcal{C} \text{ präfixfrei} \}$$

- **Huffman Codes:**



Wiederholung

- **Shannonsche Informationsmaße:**

$$H(X) = -\mathbb{E}\left(\log_2\left(p_X(X)\right)\right)$$

$$H(X, Y) = -\mathbb{E}\left(\log_2\left(p_{X,Y}(X, Y)\right)\right)$$

$$H(Y|X) = -\mathbb{E}\left(\log_2\left(p_{Y|X}(Y|X)\right)\right)$$

$$D(X||Y) = \mathbb{E}\left(\log_2\left(\frac{p_X(X)}{p_Y(Y)}\right)\right)$$


$$I(X; Y) = \mathbb{E}\left(\log_2\left(\frac{p_{X,Y}(X, Y)}{p_X(X)p_Y(Y)}\right)\right)$$

$$I(X; Y|Z) = \mathbb{E}\left(\log_2\left(\frac{p_{X,Y|Z}(X, Y|Z)}{p_{X|Z}(X|Z)p_{Y|Z}(Y|Z)}\right)\right)$$

- **Grundlegende Zusammenhänge, Kettenregeln:**

$$H(X) = H(p_X) = \log_2 |\mathcal{X}| - D(p_X||p_U)$$

$$I(X; Y) = D(p_{X,Y}||p_X \cdot p_Y)$$



$$I(X, Y; Z) = I(X; Z) + I(Y; Z|X)$$

Inhalt der letzten Vorlesungen

- 1. Verlustlose Datenkompression mit Codes variabler Länge
 - (1.1) Einführendes Beispiel, Modellbildung, Problemstellung
 - (1.2) Quellen als Datenmodell
 - (1.3) Codes variabler Länge
 - (1.4) Huffman-Codes
-

- 2. Informationsmaße für diskrete Zufallsgrößen
 - (2.1) Definition der Shannonschen Informationsmaße
 - (2.2) Symmetrien
 - (2.3) Grundlegende Zusammenhänge, Kettenregeln
 - (2.4) Nichtnegativität
-

Inhalt Vorlesung 5

- 2. Informationsmaße für diskrete Zufallsgrößen
 - (2.4) Nichtnegativität (Folien VL 4)
 \implies Fortsetzung
 - (2.5) Wichtige (Un-)Gleichungen (Folien VL 4)
 - (2.6) Beispiel / (Online-Zufallsexperiment)
 - (2.7) n -dimensionale Verallgemeinerungen
 - (2.8) Asymptotische Größen
 - (2.9) Konvexitätseigenschaften
-

(2.6) Beispiel

Wir werten in diesem Teilabschnitt das dreistufige Online-Zufallsexperiment aus der Vorlesung 3 aus (siehe Folie 21 zu Vorlesung 4).

- **W-theoretisches Modell:**

Ausgang **Zufallsexperiment 1** wird mit **Zufallsgröße** X_1 mit Alphabet \mathcal{X}_1 beschrieben

Ausgang **Zufallsexperiment 2** wird mit **Zufallsgröße** X_2 mit Alphabet \mathcal{X}_2 beschrieben

Ausgang **Zufallsexperiment 3** wird mit **Zufallsgröße** X_3 mit Alphabet \mathcal{X}_3 beschrieben

$$\mathcal{X}_1 = \mathcal{X}_2 = \mathcal{X}_3 = \{0, 1\}$$

- **Zufallsexperiment 1 (ZE 1): 2 Münzwürfe**

$$p_{X_1}(0) = \mathbb{P}(X_1 = 0) = \mathbb{P}(\text{"zweimal Kopf"}) = 1 - q_1$$

$$p_{X_1}(1) = \mathbb{P}(X_1 = 1) = 1 - p_{X_1}(0) = q_1$$

Für den Parameter $q_1 \in [0, 1]$ gilt bei unabhängigen Würfeln mit einer fairen Münze

$$q_1 = 3/4.$$

- **Zufallsexperiment 2 (ZE 2): 1 Münzwurf, Ausgang ZE 2 unabhängig von Ausgang ZE 1**

$$p_{X_2}(0) = \mathbb{P}(X_2 = 0) = \mathbb{P}(\text{"einmal Kopf"}) = 1 - q_2$$

$$p_{X_2}(1) = \mathbb{P}(X_2 = 1) = 1 - p_{X_2}(0) = q_2$$

Für den Parameter $q_2 \in [0, 1]$ gilt bei einem Wurf mit einer fairen Münze

$$q_2 = 1/2.$$

(2.6) Beispiel

- **Zufallsexperiment 3 (ZE 3):** 2 Münzwürfe, Ausgang ZE 3 abhängig von Ausgang ZE 2 aber nicht von Ausgang ZE 1.

$$\begin{aligned}p_{X_3|X_2}(1|0) &= \mathbb{P}(X_3 = 1|X_2 = 0) \\&= \mathbb{P}(\text{"zweimal Zahl bei ZE 3 unter der Bedingung Kopf bei ZE 2"}) \\&= \epsilon_1\end{aligned}$$

$$\begin{aligned}p_{X_3|X_2}(0|0) &= \mathbb{P}(X_3 = 0|X_2 = 0) \\&= 1 - p_{X_3|X_2}(1|0) \\&= 1 - \epsilon_1\end{aligned}$$

$$\begin{aligned}p_{X_3|X_2}(0|1) &= \mathbb{P}(X_3 = 0|X_2 = 1) \\&= \mathbb{P}(\text{"zweimal Kopf bei ZE 3 unter der Bedingung Zahl bei ZE 2"}) \\&= \epsilon_2\end{aligned}$$

$$\begin{aligned}p_{X_3|X_2}(1|1) &= \mathbb{P}(X_3 = 1|X_2 = 1) \\&= 1 - p_{X_3|X_2}(0|1) \\&= 1 - \epsilon_2\end{aligned}$$

Für die Parameter $\epsilon_1 \in [0, 1]$ und $\epsilon_2 \in [0, 1]$ gilt bei unabhängigen Würfeln mit einer fairen Münze

$$\epsilon_1 = 1/4 \quad \text{und} \quad \epsilon_2 = 1/4.$$

(2.6) Beispiel

- Aus den zuvor angegebenen Wahrscheinlichkeiten lassen sich sämtliche **gemeinsame/bedingte W-Funktionen** berechnen.
- (Gemeinsame) W-Funktion von X_1 und X_2 :

$$p_{X_1, X_2}(x_1, x_2) = p_{X_1}(x_1)p_{X_2}(x_2), \quad x_1, x_2 \in \{0, 1\}$$

$p_{X_1, X_2}(x_1, x_2)$		x_2		$p_{X_1}(x_1)$
		0	1	
x_1	0	$(1 - q_1)(1 - q_2)$	$(1 - q_1)q_2$	$1 - q_1$
	1	$q_1(1 - q_2)$	q_1q_2	q_1
$p_{X_2}(x_2)$		$1 - q_2$	q_2	

- (Gemeinsame) W-Funktion von X_2 und X_3 :

$$p_{X_2, X_3}(x_2, x_3) = p_{X_2}(x_2)p_{X_3|X_2}(x_3|x_2), \quad x_2, x_3 \in \{0, 1\}$$

$p_{X_2, X_3}(x_2, x_3)$		x_3		$p_{X_2}(x_2)$
		0	1	
x_2	0	$(1 - q_2)(1 - \epsilon_1)$	$(1 - q_2)\epsilon_1$	$1 - q_2$
	1	$q_2\epsilon_2$	$q_2(1 - \epsilon_2)$	q_2
$p_{X_3}(x_3)$		$(1 - q_2)(1 - \epsilon_1) + q_2\epsilon_2$	$(1 - q_2)\epsilon_1 + q_2(1 - \epsilon_2)$	

(2.6) Beispiel

- Gemeinsame W-Funktion von X_1, X_2, X_3 :

$$\begin{aligned} p_{X_1, X_2, X_3}(x_1, x_2, x_3) &= p_{X_1}(x_1)p_{X_2, X_3}(x_2, x_3) \\ &= p_{X_1}(x_1)p_{X_2}(x_2)p_{X_3|X_2}(x_3|x_2), \quad x_1, x_2, x_3 \in \{0, 1\} \end{aligned}$$

x_1	x_2	x_3	$p_{X_1, X_2, X_3}(x_1, x_2, x_3)$						
0	0	0	$(1 - q_1)$	\cdot	$(1 - q_2)$	\cdot	$(1 - \epsilon_1)$	$\frac{3}{32}$	
0	0	1	$(1 - q_1)$	\cdot	$(1 - q_2)$	\cdot	ϵ_1	$\frac{1}{32}$	
0	1	0	$(1 - q_1)$	\cdot	q_2	\cdot	ϵ_2	$\frac{1}{32}$	
0	1	1	$(1 - q_1)$	\cdot	q_2	\cdot	$(1 - \epsilon_2)$	$\frac{3}{32}$	
1	0	0	q_1	\cdot	$(1 - q_2)$	\cdot	$(1 - \epsilon_1)$	$\frac{9}{32}$	
1	0	1	q_1	\cdot	$(1 - q_2)$	\cdot	ϵ_1	$\frac{3}{32}$	
1	1	0	q_1	\cdot	q_2	\cdot	ϵ_2	$\frac{3}{32}$	
1	1	1	q_1	\cdot	q_2	\cdot	$(1 - \epsilon_2)$	$\frac{9}{32}$	

Letzte Spalte für $q_1 = \frac{3}{4}$, $q_2 = \frac{1}{2}$, $\epsilon_1 = \epsilon_2 = \frac{1}{4}$.

(2.6) Beispiel

- Das Online-Zufallsexperiment wurde 33 mal durchgeführt.
Vielen Dank an alle Teilnehmer:innen!
- Gemeinsame W-Funktion p_{X_1, X_2, X_3} für $q_1 = \frac{3}{4}$, $q_2 = \frac{1}{2}$, $\epsilon_1 = \epsilon_2 = \frac{1}{4}$ im Vergleich zu den gemessenen relativen Häufigkeiten des Zufallsexperimentes:

x_1	x_2	x_3	$p_{X_1, X_2, X_3}(x_1, x_2, x_3)$	Relative Häufigkeiten
0	0	0	$\frac{3}{32} \approx 0.09375$	$\frac{4}{33} \approx 0.121212$
0	0	1	$\frac{1}{32} \approx 0.03125$	$\frac{2}{33} \approx 0.060606$
0	1	0	$\frac{1}{32} \approx 0.03125$	$\frac{3}{33} \approx 0.090909$
0	1	1	$\frac{3}{32} \approx 0.09375$	$\frac{3}{33} \approx 0.090909$
1	0	0	$\frac{9}{32} \approx 0.28125$	$\frac{6}{33} \approx 0.181818$
1	0	1	$\frac{3}{32} \approx 0.09375$	$\frac{2}{33} \approx 0.030303$
1	1	0	$\frac{3}{32} \approx 0.09375$	$\frac{2}{33} \approx 0.060606$
1	1	1	$\frac{9}{32} \approx 0.28125$	$\frac{11}{33} \approx 0.333333$

Genauere Übereinstimmung erhält man durch eine größere Stichprobe.

(2.6) Beispiel

- Vergleich "Theorie / Praxis" mit Hilfe der relativen Entropie.
- Wir fassen die im Zufallsexperiment gemessenen relativen Häufigkeiten als \mathbb{W} en auf und nennen die zugehörige \mathbb{W} -Funktion $p^{(\text{ZE})}$.
- Den Unterschied zur theoretischen \mathbb{W} -Funktion p_{X_1, X_2, X_3} können wir mit der relativen Entropie quantifizieren.

$$\begin{aligned} D\left(p^{(\text{ZE})} \parallel p_{X_1, X_2, X_3}\right) &= \sum_{x_1, x_2, x_3 \in \{0,1\}} p^{(\text{ZE})}(x_1, x_2, x_3) \log_2 \frac{p^{(\text{ZE})}(x_1, x_2, x_3)}{p_{X_1, X_2, X_3}(x_1, x_2, x_3)} \\ &\approx 0.129848 \text{ (bit)} \end{aligned}$$

- Mit wachsender Stichprobengröße werden die beiden \mathbb{W} -Funktionen "immer gleicher" und $D\left(p^{(\text{ZE})} \parallel p_{X_1, X_2, X_3}\right)$ konvergiert gegen 0.


(2.6) Beispiel

- Wir berechnen nun einige Informationsmaße auf Basis der theoretischen W-Funktionen.
- Für die Entropien der Zufallsgrößen X_1 , X_2 und X_3 erhalten wir gemäß Definition der Entropie

$$H(X_1) = H_b(q_1), \quad H(X_2) = H_b(q_2), \quad H(X_3) = H_b((1 - q_2)\epsilon_1 + q_2(1 - \epsilon_2))$$

wobei H_b die binäre Entropiefunktion darstellt.

$$H_b(q) = -q \log_2 q - (1 - q) \log_2 (1 - q), \quad q \in [0, 1]$$



Diese einfachste Entropiefunktion illustriert bereits die generelle Konkavitätseigenschaft der Entropie.

→ allgemein siehe (2.9.2)

- Für die Parameter $q_1 = \frac{3}{4}$, $q_2 = \frac{1}{2}$, $\epsilon_1 = \epsilon_2 = \frac{1}{4}$ erhalten wir

$$H(X_1) \approx 0.811278 \text{ bit}, \quad H(X_2) = 1 \text{ bit}, \quad H(X_3) = 1 \text{ bit}$$

d. h. die Unbestimmtheit in ZE 1 ist geringer als in ZE 2 und ZE 3.

(2.6) Beispiel

- Wegen der **Unabhängigkeit** von X_1 und X_2 gilt nach (2.5.2)

$$H(X_2|X_1) = H(X_2)$$

und mit der Definition der **bedingten Entropie** erhalten wir

$$\begin{aligned} H(X_3|X_2) &= p_{X_2}(0)H(p_{X_3|X_2}(\cdot|0)) + p_{X_2}(1)H(p_{X_3|X_2}(\cdot|1)) \\ &= (1 - q_2)H_b(\epsilon_1) + q_2H_b(\epsilon_2). \end{aligned}$$

- Wegen der **Unabhängigkeit** von X_1 und X_2 gilt nach (2.5.4) und (2.4.4)

$$\begin{aligned} H(X_1, X_2) &= H(X_1) + H(X_2) \quad \text{und} \quad I(X_1; X_2) = 0. \\ &= H_b(q_1) + H_b(q_2). \end{aligned}$$

- Mit (2.3.1) erhalten wir

$$\begin{aligned} H(X_2, X_3) &= H(X_2) + H(X_3|X_2) \\ &= H_b(q_2) + (1 - q_2)H_b(\epsilon_1) + q_2H_b(\epsilon_2). \end{aligned}$$

- Mit (2.3.3) folgt

$$\begin{aligned} I(X_2; X_3) &= H(X_3) - H(X_3|X_2). \\ &= H_b((1 - q_2)\epsilon_1 + q_2(1 - \epsilon_2)) - [(1 - q_2)H_b(\epsilon_1) + q_2H_b(\epsilon_2)]. \end{aligned}$$


- Selbststudium: Warum gilt

$$I(X_1; X_3|X_2) = 0?$$

(2.6) Beispiel

- Für $\epsilon_1 = \epsilon_2 = \epsilon$ erhalten wir die **Transinformation**

$$I(X_2; X_3) = H_b((1 - q_2)\epsilon + q_2(1 - \epsilon)) - H_b(\epsilon).$$



Diese einfache Transformationsfunktion illustriert bereits die generellen **Konkavitäts-/Konvexitätseigenschaften der Transinformation**:

Bzgl. eines Arguments konvex, bzgl. des anderen Arguments konkav.

→ allgemein siehe (2.9.3/4)

- Für die Parameter $q_1 = \frac{3}{4}$, $q_2 = \frac{1}{2}$, $\epsilon_1 = \epsilon_2 = \frac{1}{4}$ erhalten wir

$$H(X_3|X_2) \approx 0.811278 \text{ bit} \leq H(X_3) = 1 \text{ bit}$$

$$H(X_1, X_2) \approx 1.811278 \text{ bit}, \quad H(X_2, X_3) \approx 1.811278 \text{ bit}, \quad I(X_2; X_3) \approx 0.188722 \text{ bit}$$

- Vergleich mit Werten der Informationsmaße für "gemessene" W-Funktion $p^{(\text{ZE})}$
⇒ Selbststudium

(2.7) n -dimensionale Verallgemeinerungen

X_1, X_2, \dots, X_n seien n diskrete Zufallsgrößen und $X = (X_1, X_2, \dots, X_n)$ der entsprechende n -dimensionale Zufallsvektor.

- **(2.7.1) Kettenregel Entropie für n Zufallsgrößen:**

$$H(X_1, X_2, \dots, X_n) = \sum_{k=1}^n H(X_k | X_{k-1}, X_{k-2}, \dots, X_1)$$

- **(2.7.2) Kettenregel Transinformation für n Zufallsgrößen:**

$$I(X_1, X_2, \dots, X_n; Y) = \sum_{k=1}^n I(X_k; Y | X_{k-1}, X_{k-2}, \dots, X_1)$$

- **(2.7.3) Unabhängigkeit maximiert Entropie für n Zufallsgrößen:**

$$H(X_1, X_2, \dots, X_n) \leq \sum_{k=1}^n H(X_k)$$

$$H(X_1, X_2, \dots, X_n) = \sum_{k=1}^n H(X_k) \iff X_1, X_2, \dots, X_n \text{ sind unabhängig}$$

(2.7) n -dimensionale Verallgemeinerungen

- Herleitung zu (2.7.1):

(2.7) n -dimensionale Verallgemeinerungen

- Herleitung zu (2.7.2):

(2.7) n -dimensionale Verallgemeinerungen

- Herleitung zu (2.7.3):

(2.7) n -dimensionale Verallgemeinerungen

- **(2.7.4) Kettenregel bedingte Entropie für n Zufallsgrößen:**

$$H(X_1, X_2, \dots, X_n | Y) = \sum_{k=1}^n H(X_k | X_{k-1}, X_{k-2}, \dots, X_1, Y)$$

- **(2.7.5) Kettenregel bedingte Transinformation für n Zufallsgrößen:**

$$I(X_1, X_2, \dots, X_n; Y | Z) = \sum_{k=1}^n I(X_k; Y | X_{k-1}, X_{k-2}, \dots, X_1, Z)$$

- **(2.7.6) Bedingte Unabhängigkeit maximiert bedingte Entropie für n Zufallsgrößen:**

$$H(X_1, X_2, \dots, X_n | Y) \leq \sum_{k=1}^n H(X_k | Y)$$

$$H(X_1, X_2, \dots, X_n | Y) = \sum_{k=1}^n H(X_k | Y) \iff X_1, X_2, \dots, X_n \text{ sind} \\ \text{bedingt unabhängig gegeben } Y$$

(2.8) Asymptotische Größen

- **(2.8.1) Entropierate:** Die Größe

$$\overline{H}(X) = \lim_{n \rightarrow \infty} \frac{H(X_1, X_2, \dots, X_n)}{n}$$

nennen wir **Entropierate** der Folge $X = (X_k)_{k \in \mathbb{N}}$ diskreter Zufallsgrößen, sofern der Grenzwert existiert.

$$X = \left(\underbrace{X_1, X_2, X_3, \dots, X_n}_{\text{Block 1}}, \underbrace{X_{n+1}, X_{n+2}, \dots, X_{2n}}_{\text{Block 2}}, \underbrace{X_{2n+1}, X_{2n+2}, \dots, X_{3n}}_{\text{Block 3}}, \underbrace{X_{3n+1}, X_{3n+2}, \dots, X_{4n}}_{\text{Block 4}}, \dots \right)$$

Bemerkung:

Die Entropierate ist u. a. eine untere Schranke für die (asymptotisch) verlustlose, "blockweise" Datenkompression, speziell bei gedächtnisbehafteten Modellen.

(2.8) Asymptotische Größen

- **(2.8.2) Transinformationsrate:** Die Größe

$$\bar{I}(X; Y) = \lim_{n \rightarrow \infty} \frac{I(X_1, X_2, \dots, X_n; Y_1, Y_2, \dots, Y_n)}{n}$$

nennen wir **Transinformationsrate** der Folgen $X = (X_k)_{k \in \mathbb{N}}$ und $Y = (Y_k)_{k \in \mathbb{N}}$ diskreter Zufallsgrößen, sofern der Grenzwert existiert.

$$X = \left(\underbrace{X_1}_{\text{blue}}, \underbrace{X_2}_{\text{blue}}, \underbrace{X_3}_{\text{blue}}, \dots, \underbrace{X_n}_{\text{blue}}, \underbrace{X_{n+1}}_{\text{blue}}, \underbrace{X_{n+2}}_{\text{blue}}, \dots \right)$$
$$Y = \left(\underbrace{Y_1}_{\text{purple}}, \underbrace{Y_2}_{\text{purple}}, \underbrace{Y_3}_{\text{purple}}, \dots, \underbrace{Y_n}_{\text{purple}}, \underbrace{Y_{n+1}}_{\text{purple}}, \underbrace{Y_{n+2}}_{\text{purple}}, \dots \right)$$

Bemerkung: Mit der Transinformationsrate kann man u. a. eine obere Schranke für die Datenrate für eine zuverlässige Datenübertragung erhalten, speziell bei gedächtnisbehafteten Modellen.

(2.8) Asymptotische Größen

- **(2.8.3) Beispiel: Entropierate einer stationären gedächtnislosen Quelle**

Die Entropierate einer stationären gedächtnislosen Quelle (siehe (1.2) in VL 2)

$X = (X_k)_{k \in \mathbb{N}}$ ist gegeben durch

$$\overline{H}(X) = \lim_{n \rightarrow \infty} \frac{H(X_1, X_2, \dots, X_n)}{n} = H(X_1).$$

\implies Konkretes Beispiel siehe 2. Übung, Aufgabe 10 g)

- **Herleitung zu (2.8.3):**

(2.8) Asymptotische Größen

- **(2.8.4) Beispiel: Entropierate einer stationären Markow-Quelle**

Die Entropierate einer stationären Markow-Quelle (siehe (1.2) in VL 2)

$X = (X_k)_{k \in \mathbb{N}}$ ist gegeben durch

$$\overline{H}(X) = \lim_{n \rightarrow \infty} \frac{H(X_1, X_2, \dots, X_n)}{n} = H(X_2|X_1).$$

⇒ Konkrete Beispiele siehe 2. Übung, Aufgabe 11 c), sowie
2. Hausaufgabe, Aufgabe 15 d)

- **Herleitung zu (2.8.4):**

(2.8) Asymptotische Größen

- Herleitung zu (2.8.4):

(2.9) Konvexitätseigenschaften

• (2.9.1) Konvexkombination von \mathbb{W} -Funktionen

- Sei X eine diskrete Zufallsgröße mit dem Alphabet \mathcal{X} .
- Seien $p_X^{(1)}$ und $p_X^{(2)}$ zwei \mathbb{W} -Funktionen von X auf dem Alphabet \mathcal{X} .
- Dann definieren wir für $\lambda \in [0, 1]$ die \mathbb{W} -Funktion

$$p_X = \lambda p_X^{(1)} + (1 - \lambda) p_X^{(2)}$$

elementweise, d. h. für alle $x \in \mathcal{X}$

$$p_X(x) = \lambda p_X^{(1)}(x) + (1 - \lambda) p_X^{(2)}(x).$$

- Die \mathbb{W} -Funktion p_X heißt **Konvexkombination der \mathbb{W} -Funktionen $p_X^{(1)}$ und $p_X^{(2)}$** .
- Zahlenbeispiel: Alphabet $\mathcal{X} = \{1, 2, 3, 4\}$ und \mathbb{W} -Funktionen

x	1	2	3	4
$p_X^{(1)}(x)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$

x	1	2	3	4
$p_X^{(2)}(x)$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$


\Rightarrow Konvexkombination

x	1	2	3	4
$p_X(x)$	$\frac{1}{4}(1 + \lambda)$	$\frac{1}{4}$	$\frac{1}{8}(2 - \lambda)$	$\frac{1}{8}(2 - \lambda)$

(2.9) Konvexitätseigenschaften

- **(2.9.1) Konvexkombination von \mathbb{W} -Funktionen** [...]

- Illustration:



Menge der \mathbb{W} -Funktionen auf dem Alphabet \mathcal{X}

- Eine Konvexkombination von \mathbb{W} -Funktionen entsteht folgendermaßen:

X_1 diskrete Zufallsgröße mit endlichem Alphabet \mathcal{X} und \mathbb{W} -Funktion p_{X_1}

X_2 diskrete Zufallsgröße mit endlichem Alphabet \mathcal{X} und \mathbb{W} -Funktion p_{X_2}

Z diskrete Zufallsgröße mit binärem Alphabet $\{1, 2\}$ und \mathbb{W} -Funktion p_Z

$$p_Z(1) = \mathbb{P}(Z = 1) = \lambda \quad \text{und} \quad p_Z(2) = \mathbb{P}(Z = 2) = (1 - \lambda)$$

Die Zufallsgröße $X = X_Z$ hat die \mathbb{W} -Funktion


$$p_X = \lambda p_{X_1} + (1 - \lambda) p_{X_2}.$$

(2.9) Konvexitätseigenschaften

- **(2.9.1) Konvexkombination von W-Funktionen** [. . .]

- **Erläuterungen:** Die Zufallsgröße Z hat die Wirkung eines Schalters, der zwischen den Zufallsgrößen X_1 und X_2 mit den Werten λ und $1 - \lambda$ auswählt.

Falls $Z = 1$, dann gilt $X = X_1$.



Falls $Z = 2$, dann gilt $X = X_2$.

Die W-Funktion p_X von $X = X_Z$ erhält man als Rand-W-Funktion von $p_{X,Z}$.


$$\begin{aligned} p_X(x) &= \sum_{z \in \mathcal{Z}} p_{X,Z}(x, z) \\ &= \sum_{z \in \mathcal{Z}} p_Z(z) p_{X|Z}(x|z) \\ &= p_Z(1) p_{X|Z}(x|1) + p_Z(2) p_{X|Z}(x|2) \\ &= \lambda p_{X_1}(x) + (1 - \lambda) p_{X_2}(x) \end{aligned}$$

(2.9) Konvexitätseigenschaften

- (2.9.2) Konkavität der Entropie:**

Die Entropie $H(X) = H(p_X)$ einer diskreten Zufallsgröße X ist **konkav bezüglich der \mathbb{W} -Funktion p_X** . D. h. für alle \mathbb{W} -Funktionen $p_X^{(1)}$ und $p_X^{(2)}$ von X und alle $\lambda \in [0, 1]$ gilt

$$H\left(\lambda p_X^{(1)} + (1 - \lambda)p_X^{(2)}\right) \geq \lambda H\left(p_X^{(1)}\right) + (1 - \lambda)H\left(p_X^{(2)}\right).$$



Bemerkung: Die Konkavität ist relevant bei der Maximierung der Entropie.

(2.9) Konvexitätseigenschaften


- Herleitung zu (2.9.2):

(2.9) Konvexitätseigenschaften

- **(2.9.3) Konkavität der Transinformation $I(p_X, p_{Y|X})$ bezüglich p_X :**

Die Transinformation $I(X; Y) = I(p_X, p_{Y|X})$ zwischen den diskreten Zufallsgrößen X und Y ist **konkav bezüglich der \mathbb{W} -Funktion p_X** bei fester bedingter \mathbb{W} -Funktion $p_{Y|X}$. D. h. für alle \mathbb{W} -Funktionen $p_X^{(1)}, p_X^{(2)}$ von X und alle $\lambda \in [0, 1]$ gilt

$$I\left(\lambda p_X^{(1)} + (1 - \lambda)p_X^{(2)}, p_{Y|X}\right) \geq \lambda I\left(p_X^{(1)}, p_{Y|X}\right) + (1 - \lambda)I\left(p_X^{(2)}, p_{Y|X}\right).$$



Bemerkung:

Die Konkavität ist relevant bei der Maximierung der Transinformation bzgl. p_X .

(2.9) Konvexitätseigenschaften

- Herleitung zu (2.9.3):


(2.9) Konvexitätseigenschaften

- **(2.9.4) Konvexität der Transinformation $I(p_X, p_{Y|X})$ bezüglich $p_{Y|X}$:**

Die Transinformation $I(X; Y) = I(p_X, p_{Y|X})$ zwischen den diskreten Zufallsgrößen X und Y ist **konvex bezüglich der bedingten \mathbb{W} -Funktion $p_{Y|X}$** bei fester

\mathbb{W} -Funktion p_X . D. h. für alle bedingten \mathbb{W} -Funktionen $p_{Y|X}^{(1)}, p_{Y|X}^{(2)}$ von Y unter der Bedingung X und alle $\lambda \in [0, 1]$ gilt

$$I(p_X, \lambda p_{Y|X}^{(1)} + (1 - \lambda) p_{Y|X}^{(2)}) \leq \lambda I(p_X, p_{Y|X}^{(1)}) + (1 - \lambda) I(p_X, p_{Y|X}^{(2)}).$$



Bemerkung:

Die Konvexität ist relevant bei der Minimierung der Transinformation bzgl. $p_{Y|X}$.

Herleitung: Bei Bedarf später.